

모델링 미팅 1페이지 (섬망 예측 / 평가 단위 split)

저장소: <https://github.com/dlwldn4824/NeSy-SMP-repro>

상세:

30초 오프닝

예측 단위를 stay -> CAM 평가 시점으로 바꿨습니다. instance 29,500 -> 345,505.
무학습 baseline 을 먼저 잰더니 변수 2개짜리 룩업표가 전체 AUROC 84.9 를 냅니다 -
전체 지표는 헤드라인으로 못 씁니다. 계층(기저 12/78/53%)을 섞어서 나온 수입니다.
진짜 여백은 앵커=N(신규 발생) 하나이고, 거기 baseline 은 AUPRC 23.0 입니다.
mobility/pain/GCS 를 추출해 4단계까지 다시 돌렸습니다. 23.0 -> 48.9(XGB).
신경망은 backbone 을 뭘로 바꿔도 XGBoost 를 못 넘습니다 (BiLSTM 45.6, MLP 45.8, 같은 입력 XGB 47.6).
개념 병목 비용은 대부분 우리 인코딩 탓이었고(-17.5 -> -3.2), 그래서 5단계를 붙였습니다.
결과: 논리층은 예측을 전혀 개선하지 않습니다 (+0.1, SD 0.4).
대신 가이드라인 정합성은 확실히 올라갑니다 - 공리 만족도가 전 항목에서 상승합니다.
지식 주입이 성능이 아니라 정합성을 사는 것이라는 결과입니다.

1) 넘어야 할 선, 그리고 1~4단계 결과 (환자 단위 70/30, test 103,306 instance)

계층	n	Positive%	B0 F1(bin)	B0 F1(macro)	B2 AUROC	B2 AUPRC
전체	103,306	31.0	61.8	73.9	84.9	71.6
앵커=N (신규 발생)	68,961	12.0	35.5	64.1	63.7	23.0
앵커=P (지속/회복)	21,692	78.1	76.3	58.9	62.3	83.0
앵커=U (관측 불가)	12,653	53.3	54.2	61.4	64.1	65.5

• B0 = 직전 확정 상태를 그대로 이월 (prev==P -> 1). 학습 없음.

• B2

B2 룩업표 (train, Positive%):

직전 w 앵커	N	P	U
N	9.0	64.8	45.7
P	43.4	85.4	78.1
없음	10.8	69.8	42.3

[!] 여기서 나오는 결론 하나

전체 AUROC 84.9 는 "예측을 잘해서"가 아니라 계층의 기저율이 12% / 78% / 53% 로 갈라져 있어서 나온다.

계층
알 수

이건 우리가 이미 한 번 겪은 함정과 같은 종류다 - MEETING_ONEPAGER.md §2 의 Table 1(macro) vs Table 2(binary). 집계 방식이 헤드라인을 만든다. 이번엔 미리 못 박고 시작한다.

1~4단계 결과 - 같은 분할, 같은 test (AUPRC)

계층	기저%	1 lookup	2 XGB	3 BiLSTM	4 CBM-5	4x 이진-15	4c 연속-17	4f free-17
전체	31.0	71.6	82.8	81.6	70.1	77.2	80.1	81.6
앵커=N (주 지표)	12.0	23.0	48.9	45.6	30.4	38.4	42.2	45.7
앵커=P	78.1	83.0	90.6	89.8	84.7	85.8	88.6	89.8
앵커=U	53.3	65.5	82.3	80.9	70.3	76.2	79.3	81.0

4f free-17 = 같은 17차원 병목인데 개념 지도학습만 빼 대조군. 폭 효과와 개념 효과를 가른다.
2단계에서 주 지표 AUPRC 가 두 배 이상이 됐고, 3·4단계는 그걸 넘지 못했다.

계층별

단계별 증분 (앵커=N AUPRC)

시드 3개 (42/7/2024) 반복 - 앵커=N AUPRC 평균 ± 표준편차

모델	평균 ± SD	시드별	병목 비용
3 BiLSTM (병목 없음)	45.6 ± 0.1	45.6 / 45.6 / 45.5	-
4 CBM-5 (이진)	28.1 ± 2.5	30.4 / 29.2 / 24.6	-17.5
4x 이진-15	37.6 ± 0.7	38.4 / 37.7 / 36.6	-8.0
4c 연속-17	42.4 ± 0.5	42.2 / 43.1 / 41.9	-3.2
4f free-17 (개념 지도학습 없음)	45.5 ± 0.2	45.7 / 45.5 / 45.2	-0.1
5 LTN (공리 12개, w_K=0.2)	43.1 ± 0.1	43.0 / 43.2 / 43.1	-2.4

해석 - 병목 비용의 정체

비교	Δ	뜻
연속 - 이진	+4.8	인코딩만 바꿔 회수한 몫 (SD 0.5·0.7 이라 확실)
연속의 남은 비용 (vs free-17)	-3.1	진짜 '개념 밖 신호'의 추정치
자유 병목 자체 (vs 병목 없음)	-0.1	폭은 문제가 아니다

[!] 직전 해석("개념 밖에 10점어치 신호가 있다")은 과했다. 정정한다.
그때 유보했던 두 갈래 - "가이드라인 개념이 원래 부족하다" vs "우리 정의가 거칠다" - 중 후자가 대부분이었다. 이진 임계를 연속값으로 바꾼 것만으로 4.8 점을 회수했다.
폭이 2 늘어난 효과는 아니다 - free-15(45.2) -> free-17(45.5) 로 0.3 에 불과하다.

[o] 5단계에 좋은 소식이다. 논리층이 없히는 개념 공간이 무제약 표현 대비 -3.2 밖에 손해보지 않는다. 개념 병목이 NeSy 의 발목을 잡을 거라는 우려는 상당 부분 해소됐다.

남은 -3.1 이 '가이드라인 개념 밖에 있는 신호'의 현재 추정치다. 더 줄일 수 있는지는 다중 임계·상호작용 개념으로 더 밀어볼 수 있지만, 5단계를 미룰 만한 크기는 아니다.

[o] 분산도 계속 줄었다: 2.5(이진 5) -> 0.7(이진 15) -> 0.5(연속 17).

이득이 어디서 오나 - 피쳐군 ablation (앵커=N AUPRC)

피처군	n_feat	AUPRC	증분
A 상태만 (앵커·직전상태)	6	23.0	- (1단계와 정확히 일치)
B +CAM 이력 (경과시간·이전 P 수·UTA 비율·간격)	13	34.4	+11.4
C +RASS (24h 요약 6종 + 깊은진정)	20	41.0	+6.6
D +진정제 (benzo·propofol·dexmed)	24	41.1	+0.1
E +정적 (age·careunit·era·los)	29	46.0	+4.9
F +mobility·pain·GCS	60	48.9	+2.9

읽을 것 넷.

1. A 가 1단계 룩업(23.0)과 정확히 일치한다 - 파이프라인 sanity check 통과.

2. CA

계층별 전체 지표 - AUPRC 와 AUROC 가 서로 다른 이야기를 한다

지금까지 앵커=N 만 보고했는데, P·U 계층과 AUROC 를 같이 놓으면 읽는 법이 달라진다.

AUPRC (기저: 전체 31.0 · N 12.0 · P 78.1 · U 53.3)

계층	1 lookup	2 XGB	3 BiLSTM	4c CBM-21	5 LTN
전체	71.6	82.8	81.5	80.4	80.3
앵커=N	23.0	48.9	45.6	43.3	43.0
앵커=P	83.0	90.6	89.7	88.9	88.8
앵커=U	65.5	82.3	80.5	79.2	79.2

AUROC

계층	1 lookup	2 XGB	3 BiLSTM	4c CBM-21	5 LTN
전체	84.9	91.4	90.7	89.9	89.9
앵커=N	63.7	85.2	83.6	81.4	81.2
앵커=P	62.3	74.5	72.3	70.5	70.3
앵커=U	64.1	82.1	79.8	78.2	78.0

기저 보정 AUPRC = (AUPRC - 기저) / (100 - 기저) · 0=무작위 · 100=완전

계층	기저%	1 lookup	2 XGB	3 BiLSTM	4c CBM-21	5 LTN
----	-----	----------	-------	----------	-----------	-------

전체	31.0	58.9	75.1	73.2	71.6	71.5
앵커=N	12.0	12.5	41.9	38.2	35.5	35.2
앵커=P	78.1	22.2	57.0	52.9	49.2	48.8
앵커=U	53.3	26.1	62.1	58.2	55.5	55.5

[I] 여기서 나오는 것 셋

- ① AUROC 는 전 계층에서 유지·상승한다. lookup -> XGB 로 N +21.5 · P +12.2 · U +18.0 · 전체 +6.5.
- ② "N 은 못하고 P 는 잘한다"는 인상은 AUPRC 의 기저율 스케일 때문이다. 지표를 바꾸면 뒤집힌다.
- ③ 실제로 가장 어려운 계층은 앵커=P 다.

모델 순위는 두 지표·네 계층에서 모두 같다 - XGB > free-21 ~ BiLSTM > CBM-21 ~ LTN > 이진 CBM > CBM-5 > lookup.

5단계 - PADIS 공리를 없으면

컴파일된 19개 중 12개를 강제한다. 처음엔 8개였는데, eda/25_ 로 수혈(inputevents)과

성능: 8개일 때도, 12개로 늘려도 달라지지 않는다.

	4단계 CBM	5단계 LTN
공리 8개 (개념 17)	42.4 ± 0.5	42.5 ± 0.4
공리 12개 (개념 21)	43.2 ± 0.1	43.1 ± 0.1

공리를 1.5배로 늘려도 -0.1. SD 가 0.1 로 줄어 이제는 확실한 null 이다.

공리 만족도 - 두 가지를 분리해서 봐야 한다.

④ 벤조 규칙 - 데이터는 지지하는데 모델이 안 따른다

[I] 직전 보고("데이터가 Benzo·Dexmed 를 거부한다")는 철회한다. 계산이 틀렸다.
 모델 적합성은 $1 - \sqrt{\text{mean}(\text{위반}^2)}$ (p=2, 큰 위반에 큰 벌점)로, 내가 넣은 기준은 $1 - P(A)(1-P(B))$ (산술평균)로 재고 둘을 뺐다. 100명 중 4명이 위반하면 전자는 0.80, 후자는 0.96 - 같은 답안에 16점 차가 난다. 게다가 기준은 실제 라벨, 모델은 예측값이라 예측 오차까지 섞였다. 그 표의 '기준 대비' 열은 무효다.

고친 방법: 두 질문을 분리한다.

(가) 규칙이 이 코호트에서 성립하나 - 모델을 거치지 않고 실제 라벨만으로

공리	GRADE	n(A)	P(BW	A)	P(BW	¬A)	위험차	위험비
SedationIntensity -> Delirium	cohort	15,202	61.4	25.7	+35.7	2.39		
DeepSedation -> CurrentUTA	derived	6,677	42.6	10.2	+32.5	4.20		
EarlyMobility -> ¬Delirium	low	10,960	92.5	66.3	+26.2	1.40		
Benzo -> Delirium	strong	5,166	55.6	29.7	+25.9	1.87		
Dementia -> Delirium	strong	5,824	54.1	29.6	+24.5	1.83		
DeepSedation -> Delirium	low	6,677	44.9	30.0	+14.9	1.50		
Trauma -> Delirium	strong	12,445	39.8	29.7	+10.1	1.34		
OlderAge -> Delirium	strong	53,704	33.1	28.7	+4.4	1.15		
Hypertension -> Delirium	moderate	73,958	32.2	27.9	+4.3	1.15		
BloodTransfusion -> Delirium	strong	10,697	32.1	30.8	+1.3	1.04		
SeverePain -> Delirium	inconclusive	25,618	13.6	36.7	-23.1	0.37		
Dexmed -> ¬Delirium	moderate	8,061	43.1	71.2	-28.2	0.60		

Benzo -> Delirium 은 가장 잘 지지되는 규칙 속에 든다 (위험비 1.87). 정반대로 보고했었다.

[!] 음수 두 개는 가이드라인이 틀렸다는 뜻이 아니라 교란·선택효과로 읽어야 한다.

Dexmed 는 초조한 환자에게 투여되는 적응증 교란·역인과(padis/docs §5 가 지정한 그것),

SeverePain 은 NRS 를 매길 수 있는 환자가 곧 의사소통 가능한 환자라는 선택효과다.

보정 없는 주변 연관이라 인과로 읽으면 안 된다.

(나) 모델이 규칙을 따르나 - 데이터 만족도와 같은 집계·같은 하드 라벨로

공리	데이터 만족도	모델(4단계)	모델-데이터
Benzo -> Delirium	0.851	0.572	-0.279
Dexmed -> ¬Delirium	0.789	0.713	-0.076
EarlyMobility -> ¬Delirium	0.911	0.908	-0.003
(나머지 9개)			전부 양수

[!] 살아남은 결과는 이것 하나다: Benzo 만 모델이 데이터보다 규칙을 덜 지킨다 (-0.279).

데이터는 위험비 1.87 로 규칙을 지지하는데 모델은 그 규칙을 쓰지 않는다.

2단계 ablation 에서 진정제 노출의 예측 기여가 +0.1 이었던 것과 일치한다 -

CAM 이력이 벤조의 효과를 이미 매개하고 있어서 조건부로는 추가 정보가 없는 것으로 보인다.

(주변 연관 vs 조건부 기여의 차이이지, 규칙이 틀렸다는 뜻이 아니다.)

[o] 그리고 논리층이 정확히 이 지점을 메운다. LTN 을 켜면 Benzo 정합성이 0.572 -> 0.776 으로 오른다(w_K=0.5). 예측 성능은 그대로인데 모델이 가이드라인을 더 따르게 된다. 논리층이 무엇을 위한 것인지 처음으로 구체적으로 보이는 사례다.

2) 모델 사다리 - 무엇을 순서대로 돌리나

단계	모델	확인 목적	새로 만들 것	재사용
1	Carry-forward · lookup baseline	CAM 이력만으로 가능한 성능	[o] 완료	eda/20_
2	XGBoost	요약된 정적 변수만으로 가능한 성능	[o] 완료 (mobility/pain/GCS 빠진 채)	eda/22_
3	BiLSTM	원시 24h 시계열이 요약될 넘나	[o] 완료 (RASS+진정제 채널만)	eda/23_
4	CBM	PADIS 임상 개념을 명시적으로 예측하는 효과	[o] 완료 (이전 15 · 연속 17 · 자유 대조군)	eda/23_
5	LTN	CBM + PADIS 논리 공리의 효과	[o] 완료 (공리 12개 강제)	eda/23_
6	LNN	구간 진리값이 라벨 미관찰 문제에 실제로 필요한지	[!] 전부 구현	없음 (공개 구현 빈약)

5와 6은 쌓는 게 아니라 대안 논리 프레임워크로 비교한다. LNN 은 구현이 덜 성숙하고, 라벨 미관찰을 [0,1] 로 둔다고 실제 결과가 복원되는 것도 아니다. 4-5 결과를 본 뒤 6의 적용 여부를 결정한다 (§4-5 게이트).

입력 / 출력 (확정, SPLIT_SPEC.md §3)

X [시계열] 앵커 이전 24h — RASS(커버 100%, median 5회) · 진정제 3계열

Assessable 을 보조 출력으로 두면 라벨 못 붙인 29.0% 가 Assessable=0 의 양성 예시로 재활용된다.

[!] 그런데 실제로 해보니 도움이 안 됐다 (4b, 앵커=N AUPRC -3.9). 설계 의도는 맞았을 수 있으나 이 구현에서는 미관찰 앵커를 넣자 배치당 라벨 표본이 줄어 과제 손실 기울기가 묻어지는 부작용이 있다. 손실 가중·배치 구성을 고쳐 다시 봐야 하고, 그 전까지는 "재활용하면 이득"이라고 말할 수 없다.

개념층 · 논리층 구성

[시계열 신경망] 이전 24h RASS · 약물 · mobility · pain · GCS · 활력징후

공리마다 입력 시점을 명시해야 한다. 위험요인 공리(Benzo -> Delirium)는 앵커 이전 24h 노출을,

[!] 라벨 미관찰 29.0% 는 무작위가 아니다 - 방향이 반대인 두 집단

원인	instance	미관찰 중	stay 사망률
----	----------	-------	----------

전부 UTA (평가는 했는데 확정 아님)	60,537	43.0%	36.1%
ICU 퇴실	46,191	32.8%	4.1%
재원 중인데 미평가	26,112	18.5%	14.8%
240h 캡에 걸림	4,482	3.2%	25.2%
사망	3,517	2.5%	100%

(참고: 라벨 생성된 군의 stay 사망률은 10.3%)

통째로 masking 하면 사망률 4.1% 집단과 36.1% 집단을 같이 버린다. 앵커 상태별로도 걸린다 -

UTA
나감)

6단계(LNN)의 대상이 여기서 좁혀진다. 구간 진리값이 필요한 것은 '전부 UTA' 60,537건(전체 앵커의 12.4%) 이지 미관찰 29% 전부가 아니다. ICU 퇴실은 경쟁위험이라 구간 문제가 아니고 별도로 다뤄야 한다.

[!] 기존 코드에서 반드시 고쳐야 하는 곳

위치	지금	바꿀 것
reproduce_tables.py 336-339	StratifiedKFold 를 기록 단위로, key=hadm_id	StratifiedGroupKFold(groups=subject_id) - 안 고치면 환자의 88.3% 가 train/test 양쪽에 걸린다
model/models.py 46	nn.Linear(23, h) (동반질환 23 고정)	정적+누적 블록 차원으로
stratified_main.py 539-540	w_D/w_K = 0.8/0.2 하드코딩	GRADE 기반 (padis_rules_draft_v1.json 에 등급 있음)

3) 평가 프로토콜 - 미리 못 박는다

주 지표 앵커=N 계층의 AUPRC (기저 12.0%, baseline 23.0)

분할

함께 보고할 것 - 하나라도 빠지면 헤드라인이 왜곡된다:

	지표
같은 계층	AUROC · F1 · precision · recall
다른 계층	앵커=P · 앵커=U 각각
전체	참고용으로만
기저 보정	정규화 AUPRC · 계층끼리 비교할 때 필수
baseline 대비	lookup(B2) 대비 개선량 <- 실질 기여도
하위군	연도(era)별 · ICU 유형별
신뢰도	calibration
논리층	모델 정합성(모델 예측) 과 데이터 일치도(실제 라벨) 를 분리 보고 · 집계 통일 필수

왜 AUPRC 인가: 앵커=N 계층은 기저 12% 다. 이 불균형에서 AUROC 는 둔하고, "새로 생길 사람을 미리 잡는다"는 임상 주장은 정밀도-재현율 곡선에 직접 대응한다.

4) 한계 6가지 (먼저 말하기)

1. ~~mobility / pain / GCS 값이 없다~~ -> 해소. eda/24_ 로 추출했다(풀스캔 74초). 다만 itemid 별 척도가 섞여 있어 쓸 것만 골랐다 - mobility 6개 중 2개, pain 5개 중 2개만 값으로 쓴다(SPLIT_SPEC §3).

2. 앵
basel

5) 교수님께 확인할 질문

1. 주 지표를 "앵커=N 계층 AUPRC"로 잡는 데 동의하시는지?

->

6) 다음 작업

#	할 일	상태
1	mobility · pain · GCS 실제 시계열 값 재추출	[o] 완료 (eda/24_)
2	24h 내 확정 CAM 없는 이유를 퇴실/사망/전부 UTA/미평가로 분리	[o] 완료 (§2)
3	환자 단위 split 데이터셋 생성	[o] 완료 (eda/22_ 안에)
4	XGBoost-BiLSTM 실행해 시계열의 추가 가치 확인	[o] 완료 - 시계열은 값을 못 더했다
5	PADIS 규칙 19개의 근거·관계 방향을 사람이 검토	대기
6	SNOMED CT 숫자 코드 검증	일부만 채움 (delirium_kg.py 제공분)
7	새 관계(decreasesRiskOf/hasNoEffectOn/precludes	[o] 완료 (19개 컴파일)
8	CBM LTN 관리 규칙 LNN 도입 필요성 판단	CBM 완료 · LTN 이 임계경로

가장 중요한 미완성 3개: ① mobility·pain·GCS 값 추출 · ② PADIS KG -> LTN loss 변환 경로 · ③ 규칙 사람 검토

순서 제안: 1~5단계가 다 돌아왔다. 다음은 결정 사항이지 구현이 아니다.

7) 붙임 - 숫자 출처

수	스크립트	산출물
instance 345,505 / 환자 40,070 / 계층 3중	eda/19_split_spec.py	out_split/spec2_*.csv
baseline B0-B2	eda/20_baseline_carryforward.py	out_split/base_carryforward.csv
입력 커버리지 (RASS 100% 등)	eda/19_split_spec.py	out_split/spec3_*.csv
라벨 미관찰 원인 5종 + 사망률	eda/21_censoring_reasons.py	out_split/cens*.csv
2단계 XGB + 피쳐군 ablation	eda/22_stage2_xgb.py	out_split/stage2_xgb.csv · stage2_ablation.csv
3·4·5단계 + 시드반복 + 공리 만족도	eda/23_stage34_bilstm_cbm.py	out_split/stage34.csv · stage34_seeds.csv · stage5_axiom_sat.csv
mobility·pain·GCS 보충추출	eda/24_extract_mobility_pain_gcs.py	notes/eda/_extra_values.parquet
PADIS 규칙 19개 + 근거등급	-	padis/kg/delirium_kg.py(본문) · padis/outputs/padis_rules_draft_v1.json(MIMIC 매핑)
LTN 공리 19개 컴파일	NeSy-SMP/pipeline/horn_to_ltn.py	configs/padis_concepts.json · relation_vocab.json

전제: 성인 + ICU LOS $\geq$ 24h + 입실 후 240h 캡. 분할 seed 42.