

모델링 미팅 1페이지 (섬망 예측 / 평가 단위 split)

저장소: <https://github.com/dlwldn4824/NeSy-SMP-repro>

상세:

30초 오프닝

예측 단위를 stay -> CAM 평가 시점으로 바꿨습니다. instance 29,500 -> 345,505.
무학습 baseline 을 먼저 잰더니 변수 2개짜리 룩업표가 전체 AUROC 84.9 를 냅니다 -
전체 지표는 헤드라인으로 못 씁니다. 계층(기저 12/78/53%)을 섞어서 나온 수입니다.
진짜 여백은 앵커=N(신규 발생) 하나이고, 거기 baseline 은 AUPRC 23.0 입니다.
4단계까지 돌렸습니다. 23.0 -> 46.1(XGB) 로 두 배가 됐고, 3·4단계는 그걸 넘지 못했습니다.
다만 mobility/pain/GCS 가 빠진 상태라 시계열·개념층에 불리한 조건입니다.

1) 넘어야 할 선, 그리고 1~4단계 결과 (환자 단위 70/30, test 103,306 instance)

계층	n	Positive%	B0 F1(bin)	B0 F1(macro)	B2 AUROC	B2 AUPRC
전체	103,306	31.0	61.8	73.9	84.9	71.6
앵커=N (신규 발생)	68,961	12.0	35.5	64.1	63.7	23.0
앵커=P (지속/회복)	21,692	78.1	76.3	58.9	62.3	83.0
앵커=U (관측 불가)	12,653	53.3	54.2	61.4	64.1	65.5

• B0 = 직전 확정 상태를 그대로 이월 (prev==P -> 1). 학습 없음.

• B2

B2 룩업표 (train, Positive%):

직전 w 앵커	N	P	U
N	9.0	64.8	45.7
P	43.4	85.4	78.1
없음	10.8	69.8	42.3

[!] 여기서 나오는 결론 하나

전체 AUROC 84.9 는 "예측을 잘해서"가 아니라 계층의 기저율이 12% / 78% / 53% 로 갈라져 있어서 나온다.

계층
알 수

이건 우리가 이미 한 번 겪은 함정과 같은 종류다 - MEETING_ONEPAGER.md §2 의 Table 1(macro) vs Table 2(binary). 집계 방식이 헤드라인을 만든다. 이번엔 미리 못 박고 시작한다.

1~4단계 결과 - 같은 분할, 같은 test (AUPRC)

계층	기저%	1 lookup	2 XGB	3 BiLSTM	4 CBM	4b CBM+Assess
전체	31.0	71.6	82.0	80.8	72.1	69.4

앵커=N (주 지표)	12.0	23.0	46.1	43.4	29.5	25.6
앵커=P	78.1	83.0	90.0	89.3	84.6	83.3
앵커=U	53.3	65.5	81.8	80.1	72.2	69.3

앵커=N AUROC: 63.7 -> 83.8 -> 82.3 -> 71.9 -> 74.1
 2단계에서 주 지표 AUPRC 가 두 배가 됐고, 3·4단계는 그걸 넘지 못했다.

단계별 증분 (앵커=N AUPRC)

비교	Δ	읽는 법
2 - 1	+23.1	요약 피처가 록업표를 크게 넘는다
3 - 2	-2.7	원시 시계열이 요약을 못 넘었다 (단, RASS+진정제 채널뿐)
4 - 3	-13.9	개념 병목의 비용. 개념 5개(6개 중)라 상한값이다
4b - 4	-3.9	미관찰 앵커를 Assessable 로 살린 것이 도움이 안 됐다

[!] 3단계가 2단계를 못 넘은 것은 표 형태 데이터에서 흔한 결과이지만, 여기서는 판정으로 쓸 수 없다 - mobility/pain/GCS 채널이 빠진 상태라 시계열 모델이 굼고 있다. 재추출 후 다시 봐야 한다.

이득이 어디서 오나 - 피처군 ablation (앵커=N AUPRC)

피처군	n_feat	AUPRC	증분
A 상태만 (앵커·직전상태)	6	23.0	- (1단계와 정확히 일치)
B +CAM 이력 (경과시간·이전 P 수·UTA 비율·간격)	13	34.4	+11.4
C +RASS (24h 요약 6종 + 깊은진정)	20	41.0	+6.6
D +진정제 (benzo·propofol·dexmed)	24	41.1	+0.1
E +정적 (age·careunit·era·los)	29	46.1	+5.0

읽을 것 셋.
 1. A 가 1단계 록업(23.0)과 정확히 일치한다 - 파이프라인 sanity check 통과.

2) 모델 사다리 - 무엇을 순서대로 돌리나

단계	모델	확인 목적	새로 만들 것	재사용
1	Carry-forward baseline · lookup	CAM 이력만으로 가능한 성능	[o] 완료	eda/20_

2	XGBoost	요약된 정적 변수만으로 가능한 성능	[o] 완료 (mobility/pain/GCS 빠진 채)	eda/22_
3	BiLSTM	원시 24h 시계열이 요약을 넘나	[o] 완료 (RASS+진정제 채널만)	eda/23_
4	CBM	PADIS 임상 개념을 명시적으로 예측하는 효과	[o] 완료 (개념 5/6)	eda/23_
5	LTN	CBM + PADIS 논리 공리의 효과	[!] 공리 변환 필요 (§4-3)	ltn 설치됨 stratified_main.py 553-633
6	LNN	구간 진리값이 라벨 미관찰 문제에 실제로 필요한지	[!] 전부 구현	없음 (공개 구현 빈약)

5와 6은 쌓는 게 아니라 대안 논리 프레임워크로 비교한다. LNN 은 구현이 덜 성숙하고, 라벨 미관찰을 [0,1] 로 둔다고 실제 결과가 복원되는 것도 아니다.
4-5 결과를 본 뒤 6의 적용 여부를 결정한다 (§4-5 게이트).

입력 / 출력 (확정, SPLIT_SPEC.md §3)

X [시계열] 앵커 이전 24h — RASS(커버 100%, median 5회) · 진정제 3계열

Assessable 을 보조 출력으로 두면 라벨 못 붙인 29.0% 가 Assessable=0 의 양성 예시로 재활용된다.
[!] 그런데 실제로 해보니 도움이 안 됐다 (4b, 앵커=N AUPRC -3.9). 설계 의도는 맞았을 수 있으나 이 구현에서는 미관찰 앵커를 넣자 배치당 라벨 표본이 줄어 과제 손실 기울기가 묶어지는 부작용이 있다. 손실 가중·배치 구성을 고쳐 다시 봐야 하고, 그 전까지는 "재활용하면 이득"이라고 말할 수 없다.

개념층 · 논리층 구성

[시계열 신경망] 이전 24h RASS · 약물 · mobility · pain · GCS · 활력징후

공리마다 입력 시점을 명시해야 한다. 위험요인 공리(Benzo -> Delirium)는 앵커 이전 24h 노출을,

평가

[!] 라벨 미관찰 29.0% 는 무작위가 아니다 - 방향이 반대인 두 집단

원인	instance	미관찰 중	stay 사망률
전부 UTA (평가는 했는데 확정 아님)	60,537	43.0%	36.1%
ICU 퇴실	46,191	32.8%	4.1%
재원 중인데 미평가	26,112	18.5%	14.8%
240h 캡에 잘림	4,482	3.2%	25.2%
사망	3,517	2.5%	100%

(참고: 라벨 생성된 군의 stay 사망률은 10.3%)

통째로 masking 하면 사망률 4.1% 집단과 36.1% 집단을 같이 버린다. 앵커 상태별로도 걸린다 -

UTA
나감)

6단계(LNN)의 대상이 여기서 좁혀진다. 구간 진리값이 필요한 것은 '전부 UTA' 60,537건(전체 앵커의 12.4%) 이지 미관찰 29% 전부가 아니다. ICU 퇴실은 경쟁위험이라 구간 문제가 아니고 별도로 다뤄야 한다.

[!] 기존 코드에서 반드시 고쳐야 하는 곳

위치	지금	바꿀 것
reproduce_tables.py 336-339	StratifiedKFold 를 기록 단위로, key=hadm_id	StratifiedGroupKFold(groups=subject_id) - 안 고치면 환자의 88.3% 가 train/test 양쪽에 걸린다
model/models.py 46	nn.Linear(23, h) (동반질환 23 고정)	정적+누적 블록 차원으로
stratified_main.py 539-540	w_D/w_K = 0.8/0.2 하드코딩	GRADE 기반 (padis_rules_draft_v1.json 에 등급 있음)

3) 평가 프로토콜 - 미리 못 박는다

주 지표 앵커=N 계층의 AUPRC (기저 12.0%, baseline 23.0)

분할

함께 보고할 것 - 하나라도 빠지면 헤드라인이 왜곡된다:

	지표
같은 계층	AUROC · F1 · precision · recall
다른 계층	앵커=P · 앵커=U 각각
전체	참고용으로만
baseline 대비	lookup(B2) 대비 개선량 <- 실질 기여도
하위군	연도(era)별 · ICU 유형별
신뢰도	calibration
논리층	PADIS 공리 만족도 · CBM 대비 LTN 의 개념 정렬 차이

왜 AUPRC 인가: 앵커=N 계층은 기저 12% 다. 이 불균형에서 AUROC 는 둔하고, "새로 생길 사람을 미리 잡는다"는 임상 주장은 정밀도-재현율 곡선에 직접 대응한다.

4) 한계 6가지 (먼저 말하기)

1. mobility / pain / GCS 값이 아직 없다. 00_extract.py 의 VALUE_IDS 가 CAM·RASS 만 값으로 뽑는다. DB 엔 다 있다(보유율 100 / 96.2 / 100%). 재추출 전엔 3단계(BiLSTM) 입력이 반쪽이다 - 유일한 하드 블로커.

2. 앵
basel

5) 교수님께 확인할 질문

1. 주 지표를 "앵커=N 계층 AUPRC"로 잡는 데 동의하시는지?

6) 다음 작업

#	할 일	상태
1	mobility · pain · GCS 실제 시계열 값 재추출 (00_extract.py VALUE_IDS)	[!] 블로커
2	24h 내 확정 CAM 없는 이유를 퇴실/사망/전부 UTA/미평가로 분리	[o] 완료 (§2)
3	환자 단위 split 데이터셋 생성	[o] 완료 (eda/22_ 안에)
4	XGBoost-BiLSTM 실행해 시계열의 추가 가치 확인	[o] 완료 - 재추출 후 재실행 필요
5	PADIS 규칙 19개의 근거·관계 방향을 사람이 검토	대기
6	SNOMED CT 숫자 코드 검증	일부만 채움
7	새 관계(decreasesRiskOf/hasNoEffectOn/precludes)	[!] 미착수
8	CBM 1의 규칙 변환 LTN 도입 필요성 판단	CBM 완료 · LTN 이 임계경로

가장 중요한 미완성 3개: ① mobility·pain·GCS 값 추출 · ② PADIS KG -> LTN loss 변환 경로 · ③ 규칙 사람 검토

순서 제안: 1(재추출) 과 7(LTN 변환) 은 독립이라 병렬로 간다.

7) 붙임 - 숫자 출처

수	스크립트	산출물
instance 345,505 / 환자 40,070 / 계층 3중	eda/19_split_spec.py	out_split/spec2_*.csv
baseline B0-B2	eda/20_baseline_carryforward.py	out_split/base_carryforward.csv
입력 커버리지 (RASS 100% 등)	eda/19_split_spec.py	out_split/spec3_*.csv

라벨 미관찰 원인 5종 + 사망률	eda/21_censoring_reasons.py	out_split/cens*.csv
2단계 XGB + 피쳐군 ablation	eda/22_stage2_xgb.py	out_split/stage2_xgb.csv · stage2_ablation.csv
3·4단계 BiLSTM·CBM	eda/23_stage34_bilstm_cbm.py	out_split/stage34.csv
PADIS 규칙 19개 + 근거등급	-	padis/kg/delirium_kg.py(본문) padis/outputs/padis_rules_draft_v1.json(MIMIC 매핑)

전제: 성인 + ICU LOS $\geq$ 24h + 입실 후 240h 캡. 분할 seed 42.