

NeSy-SMP 재현 보고서 (교수님 확인용)

• 저장소: <https://github.com/dlwldn4824/NeSy-SMP-repro>

• 원

1. 재현 목적 및 범위

공개 NeSy-SMP 학습 코드를 기반으로 MIMIC-IV에서 end-to-end 재현을 수행하였다.
공개 GitHub에는 모델·학습 루프는 있으나, 논문에서 사용한 다음 산출물은 제공되지 않는다.

- 최종 Sepsis-3 환자 목록

• 코호

따라서 원천 DB -> 입력 CSV -> 5-fold 학습·평가 파이프라인을 직접 재구축한 뒤 공개 모델을 실행하였다.
현재 단계는 exact reproduction이 아니라 partial reproduction이다.
(공개 구현 재실행 + 논문·GitHub·재현 조건 차이 식별)

2. 논문 vs 공개 GitHub vs 현재 재현


항목	논문	공개 GitHub	현재 재현
원천 데이터	MIMIC-IV	미제공	로컬 MIMIC-IV SQLite
패혈증 선정	Sepsis-3	최종 코호트/목록 없음	ICD 1차 -> Sepsis-3 근사 2차
환자 수	약 19,328	미제공	ICD 약 9,959 / S3 근사 약 18,899
사망률	약 18%	미제공	ICD 26.2% / S3 근사 18.6%
Observation	24h	완성 CSV 가정	직접 생성
Lead time	6/12/24/48h	입력 파일 가정	직접 생성
생존자 window	ICU 내 무작위	np.random (업스트림 시드 미고정)	make_leadtime_csvs.py seed=32
동반질환 23개	임상노트 NLP	완성 데이터 미제공	주요 실험 전부 0 / 추가 ICD proxy
결측	논문 상세 처리 확인 불가	스키마 가정	없는 열 생성 후 0 대체 + ffill (코드상)
모델	RF, XGB, BiLSTM, LTN, NeSy	구현 제공	동일 5종 (reproduce_tables.py)
Data:Knowledge	0.8:0.2	w_data=0.8, w_knowledge=0.2 하드코딩	동일
Weak anchoring	임계값 초기화로 서술	임계값 부분집합 + FOL -> train loss	GitHub 방식 유지
BiLSTM checkpoint	본문 미명시	best save, test 전 load 없음	best val macro-F1 reload
LTN/NeSy checkpoint	본문 미명시	best save + load	best reload
Epoch	논문 설정	stratified_main.py 기본 50 / 20	예비 30 / 15

Table 1	fold 평균±SD (코드상 macro)	average="macro"	fold macro 평균
---------	------------------------	-----------------	---------------


Table 2	pooled + bootstrap (binary에 가까움)	원본 집계 스크립트 미확인	OOF binary/macro + bootstrap
---------	----------------------------------	----------------	------------------------------

3. 데이터 구축 흐름 (코드 기준)


MIMIC-IV SQLite



Sepsis cohort



Vitals Lab GCS extract



Long events

주요 스크립트:

파일	역할
data/build_cohort_sepsis3.py	Sepsis-3 근사 코호트
data/build_dataset_gcs.py	이벤트 추출
data/make_leadtime_csvs.py	6/12/24/48h window (--seed 기본 32)
data/long_to_wide.py	Wide 변환
data/build_comorbidities_icd.py / merge_comorbidities.py	ICD proxy
reproduce_tables.py	학습·Table 1/2 산출
data/preprocessing.py	스키마 정렬, 시퀀스 캡 230

4. ICD 1차 vs Sepsis-3 근사 2차

구분	환자 수	사망률
논문	약 19,328	약 18%
ICD 1차	약 9,959	26.2%
Sepsis-3 근사 2차	약 18,899	18.6%

Sepsis-3를 근사로 표기하는 이유:

1. 논문 최종 환자 목록 미공개

2. 완

[추가 재현 필요]

공식 MIMIC Code Repository derived SQL / 논문 조건과 정렬한 Sepsis-3 exact reconstruction.

5. 동반질환

	논문	현재 재현
출처	임상노트 NLP -> 23차원 0/1	주요 실험: 23차원 전부 0
추가 실험	-	ICD diagnosis -> 동일 23 label proxy

두 방식은 동일하지 않다. ICD proxy는 노트 NLP의 대체일 뿐 동일 재현이 아니다.

ICD proxy 6h (Sepsis-3 근사 코호트) - results_s3_6h_como/table1_summary.csv

모델	Acc	F1	AUC
RF	89.38	78.68	92.09
XGBoost	90.40	82.95	93.27
BiLSTM	89.71	82.64	92.58

LTN	89.60	82.53	92.53
NeSy-SMP	89.59	82.28	92.49


같은 코호트·como=0 (results/s3_6h): NeSy Acc/F1 = 89.64 / 82.54.

ICD p

[추가 재현 필요]

임상노트 기반 23개 동반질환 구축 후 재학습·비교.

6. Weak anchoring (중요)



확인됨 (코드):

- stratified_main.py 약 519-537: Lactate>4 등 threshold로 마스크

• 약 5

현재 재현: GitHub loss 제약을 그대로 사용 (reproduce_tables.py).

[추가 재현 필요]

A) GitHub 구현 · B) 논문 서술형 초기화 · C) anchoring 제거 - 3조건 비교.

7. Data / Knowledge weight 0.8 / 0.2

확인됨:

위치	내용
stratified_main.py:539-540	w_data = 0.8, w_knowledge = 0.2
stratified_main.py:648	loss = 1 - (w_data sat_agg + w_knowledge sat_agg_knowledge)
main.py:524-525, :629	동일
reproduce_tables.py:198, :263	w_D, w_K = 0.8, 0.2 -> 동일 식

확인 불가: 0.8/0.2 선택에 대한 체계적 탐색·정당화 (코드/현재 재현 자료에서 근거 없음).

[추가 실험 필요]

Knowledge weight sensitivity analysis.

8. Checkpoint

모델	공개 stratified_main.py	현재 reproduce_tables.py
BiLSTM	lstm_best.pth save만, test 전 load 없음 (약 279-290)	best val macro-F1 state reload 후 test
LTN	best save + load_state_dict	best reload
NeSy	best save + load_state_dict (ltn_w_k.pth)	best reload

BiLSTM 통일은 모델 간 공정 비교를 위한 수정이나, 공개 GitHub 원본과 달라진다.

[추가 재현 필요]

GitHub 원본 BiLSTM checkpoint vs best-reload 통일 조건 비교.

9. Epoch

	공개 stratified_main.py CLI 기본	main.py 기본	현재 예비 재현
BiLSTM (num_epochs)	50	30	30
LTN/NeSy (num_epochs_nesy)	20	20	15
reproduce_tables.py argparse 기본	-	-	40 / 20 (실제 실행은 30/15 사용)

현재 수치는 preliminary reproduction으로 구분한다.

[재실행 예정]

epoch / early stopping / validation / checkpoint를 공개·논문 조건에 맞춰 재학습.

10. Table 1 / Table 2

확인됨 (reproduce_tables.py):

- Table 1: fold별 metric_bundle(..., average="macro") -> mean±std

논문 NeSy 6h (보고값):

	F1
Table 1	80.35
Table 2	68.51

현재 ICD 6h 동일 OOF (results/ 문서화 수치):

집계	F1
fold macro mean	81.54
pooled macro	81.55
pooled binary	72.54

-> fold vs pool보다 macro vs binary 차이가 큼.

11. 성능 결과

11.1 ICD 6h - Table 1 macro (results/table1_summary.csv)

모델	Acc 논문	Acc 재현	F1 논문	F1 재현	AUC 논문	AUC 재현
RF	84.78	86.28	74.77	79.85	88.11	90.28
XGBoost	85.31	87.36	77.86	82.75	88.56	91.40
BiLSTM	83.53	86.28	76.82	81.72	85.35	89.37
LTN	85.65	85.93	79.20	81.45	88.10	89.24
NeSy-SMP	86.45	85.95	80.35	81.54	88.33	89.15

코호트·사망률이 논문과 달라 절대 비교에 한계.

11.2 Sepsis-3 근사 - NeSy 전체 lead (results/RESULTS_SEPSIS3_ALL_LEADS.md, como=0)

Lead	재현 Acc / F1	논문 Acc / F1
6h	89.64 / 82.54	86.45 / 80.35
12h	87.86 / 80.41	83.94 / 76.32

24h	87.06 / 78.22	82.93 / 74.71
48h	84.26 / 73.54	81.95 / 71.05

Lead ↑ -> 성능 ↓ 경향은 논문과 일치. 절대값은 재현이 높음.

11.3 Sepsis-3 근사 6h 상대 성능 (como=0)

모델	Acc / F1
RF	89.17 / 78.27
XGBoost	90.13 / 82.36
BiLSTM	89.96 / 82.66
LTN	89.70 / 82.70
NeSy-SMP	89.64 / 82.54

논문에서 보고된 NeSy 우위가 현재 조건에서는 명확히 재현되지 않음.

12. NeSy 우위가 약하게 나타난 점에 대한 해석

단정하지 않음. 가능한 원인:

1. 임상노트 comorbidity 미재현 (전부 0 / ICD proxy ≠ 논문)

2. Se

현재 결과만으로 Neuro-Symbolic 방법의 효과가 없다고 판단할 수 없다.

NeSy 추가 성능이 어떤 knowledge component에서 발생하는지 ablation이 필요하다.

13. 코드 audit 요약

#	항목	상태
1	survivor seed=32	확인됨 make_leadtime_csvs.py --seed default=32, default_rng(seed)
2	sequence 최대 230	확인됨 preprocessing.py FIXED_WINDOW = 230
3	공개 코드 요구 feature	확인됨 preprocess 선택 열: numeric 27 + como 23 + cat 4 (+ hadm/label)
4-5	누락/0 생성 열	부분 확인 (아래). 전수 audit는 추가 필요
6	변수별 missing rate	부분 확인 (S3 6h wide 샘플 20만 행)
7-8	w=0.8/0.2, loss 식	확인됨 (§7)
9	weak anchoring 위치	확인됨 stratified_main.py 약 519-648

10-12	checkpoint 흐름	확인됨 (\$8)
13-14	epoch	확인됨 (\$9)
15-16	T1/T2 averaging	확인됨 (\$10). 논문 T2 원본 코드는 확인 불가

결측·0 열 (S3 6h wide, 환자 단위 non-zero rate 샘플)

샘플에서 전 환자 0에 가깝게 나온 요구 열 예:

- Arterial CO2 Pressure, Daily Weight, BNP, Direct Bilirubin, Creatinine (whole blood)

(추출 맵 long_to_wide.CONCEPT_MAP에 없거나 이벤트 미추출로 스키마 맞추기용 0 열일 가능성.)

Comorbidity(병합 전 wide): any nonzero 0% (의도된 como=0 실험).

[추가 audit 필요]

전체 CSV 기준 변수·환자 결측률 전수, 논문 결측 처리와의 정렬.

[추가 검증 필요]

survivor window seed sensitivity (32 외 다수 seed).

14. 추가 재현 필요 항목 (체크리스트)

[추가 재현 필요] - Sepsis-3 exact reconstruction (공식 derived SQL 정렬)

[추가 재현 필요] - clinical-note comorbidities 23

[추가 재현 필요] - weak anchoring: paper vs GitHub vs 제거

[추가 재현 필요] - epoch / early stopping을 공개·논문 조건에 맞춤

[추가 재현 필요] - BiLSTM checkpoint 원본 vs best-reload

[추가 audit 필요] - missing-value / 0-fill 전수

[추가 검증 필요] - survivor window seed sensitivity

[추가 실험 필요] - knowledge weight sensitivity (0.8:0.2)

15. 결론

공개 NeSy-SMP 구현을 MIMIC-IV 원천 데이터부터 실제 실행 가능한 형태로 재구축하였고, 논문·GitHub·현재 재현 사이의 주요 차이(코호트, comorbidity, weak anchoring, checkpoint, epoch, 결측)를 식별하였다.

절대 성능만으로 논문의 NeSy 우위를 검증했다고 보기 어렵다. 다음 단계는 차이를 하나씩 제거·분리하는 ablation이다.